

# MindBalance: Clasificación Binaria del Estrés Académico a partir de Biomarcadores EEG

Gloria Palma Araujo  
*Facultad de Ciencias e Ingeniería*  
*Universidad Peruana Cayetano Heredia Lima, Perú*  
gloria.palma@upch.pe

Jamilet Cervantes Esponda  
*Facultad de Ciencias e Ingeniería*  
*Universidad Peruana Cayetano Heredia Lima, Perú*  
jamilet.cervantes@upch.pe

Xiomara Apaza Hurtado  
*Facultad de Ciencias e Ingeniería*  
*Universidad Peruana Cayetano Heredia Lima, Perú*  
xiomara.apaza@upch.pe

Alessia Cerna Quispe  
*Facultad de Ciencias e Ingeniería*  
*Universidad Peruana Cayetano Heredia Lima, Perú*  
alessia.cerna@upch.pe

Sebastian Norabuena Vicencio  
*Facultad de Ciencias e Ingeniería*  
*Universidad Peruana Cayetano Heredia Lima, Perú*  
sebastian.norabuena@upch.pe

Moises Meza Rodriguez  
*Facultad de Ciencias e Ingeniería*  
*Universidad Peruana Cayetano Heredia Lima, Perú*  
moises.meza@upch.pe

*Abstract*—El estrés crónico y continuo afecta a nivel cognitivo, cardiovascular y neuronal. La Organización Mundial de la Salud (OMS) reportó que alrededor del 40% de la población mundial sufre de estrés de forma continua o crónica. Este estado fisiológico puede ser caracterizado mediante el análisis de señales electroencefalográficas (EEG), principalmente a través de biomarcadores espectrales asociados a la actividad frontal cortical. El presente trabajo propone un pipeline de procesamiento digital de señales para la clasificación binaria del estrés (Basal vs. Estrés), integrando cuatro conjuntos de datos EEG adquiridos con distintos dispositivos y protocolos experimentales. Se extrajeron cinco biomarcadores por ventana de análisis: la razón Theta/Beta (TBR) y el ratio Alpha/Beta, la potencia global Alpha, la potencia Beta y la Asimetría Frontal Alfa (FAA). Se evaluaron dos estrategias de normalización: StandardScaler poblacional multiclase (V2) y normalización por basal propio del participante con clasificación binaria (V3). El clasificador binario V3 con baseline normalization, tras aumento de datos por ventaneo solapado y ajuste de hiperparámetros por GroupKFold, alcanzó  $0.724 \pm 0.060$  de accuracy por ventana (F1-macro  $0.707 \pm 0.053$ , AUC  $0.801 \pm 0.032$ ) y 82.4% (56/68) por grabación completa agregada. La validación en hardware portátil de bajo costo (NeuroBIT/BITalino, participante S01, un mismo sujeto en dos corridas de sesión) confirmó que TBR y Alpha/Beta capturan de forma coherente la

respuesta fisiológica al estrés con significancia estadística ( $p < 0.001$ ), mientras que la FAA no alcanzó significancia ( $p = 0.138$ ), consistente con su inclusión exploratoria; el modelo mejorado clasificó correctamente el 90.7% de las ventanas de Estrés y el 67.7% de las ventanas Basal de este participante. Se identifica y cuantifica el domain shift entre dispositivos como limitación central para la transferencia inter-hardware, y se demuestra que la baseline normalization por sujeto es la estrategia que efectivamente lo mitiga.

*Index Terms*—Estrés, EEG, biomarcadores EEG, TBR, ratio Alpha/Beta, Random Forest, domain shift, baseline normalization, NeuroBIT.

## I. INTRODUCCIÓN

El estrés se define como la respuesta general de activación del organismo ante estímulos que pueden percibirse como un desafío o una amenaza [1]. Desde el punto de vista fisiológico, el estrés involucra la activación del sistema nervioso central y estructuras del sistema límbico que envían señales al hipotálamo para regular al eje hipotálamo-hipófisis-suprarrenal (HPA) y al sistema nervioso simpático (SNS). De esta manera, se generan respuestas para mantener la homeostasis del organismo [2, 3]. El principal efector del eje HPA es el cortisol, conocido como la hormona del estrés, cuya concentración permite evaluar su activación fisiológica; sin embargo, cuando la demanda externa es persistente, el cuerpo recurre a la alostasis como un mecanismo de adaptación dinámica que altera diversos parámetros biológicos para

alcanzar un nuevo equilibrio. Si esta respuesta se mantiene en el tiempo, se produce un fenómeno de carga alostática que representa un continuo de desgaste neuroendocrino, lo cual favorece procesos inflamatorios sistémicos y compromete la plasticidad cerebral [2, 3].

Esto último se traduce en una reducción de la conectividad neuronal y de la capacidad del cerebro para generar nuevas redes, lo que dificulta el aprendizaje y la regulación emocional. En esa instancia, el estrés crónico presenta efectos documentados sobre la salud cardiovascular, cognitiva y mental.

A nivel mundial, la OMS ha reportado que alrededor del 40% de la población mundial sufre de estrés de forma continua o crónica, clasificándose como la epidemia de salud del siglo XXI [4]. En Perú, se ha reportado que 3 de cada 10 peruanos presenta un alto nivel de estrés [5]. Asimismo, el 85% de la comunidad educativa de 21 universidades reporta problemas de salud mental, de los cuales, la ansiedad con 82% y el estrés con 79% son más recurrentes [6]. Por lo que su detección temprana y objetiva es de interés tanto clínico como en contextos cotidianos, ya sean educativos o laborales.

Los métodos tradicionales de evaluación del estrés dependen predominantemente de autorreportes y cuestionarios psicométricos, los cuales son susceptibles a sesgos subjetivos y no permiten un monitoreo continuo o en tiempo real [7]. El electroencefalograma (EEG) ofrece una alternativa objetiva, no invasiva y de alta resolución temporal para caracterizar estados de activación cortical asociados al estrés [8]. Sin embargo, la mayoría de los estudios en la literatura se basan en datasets adquiridos con un único dispositivo y protocolo experimental, lo que limita la generalización de los modelos resultantes a otros contextos de adquisición. Adicionalmente, la calidad de señal, la densidad de electrodos y la ubicación de las referencias, genera una heterogeneidad topográfica difícil de armonizar mediante técnicas de normalización estándar [9].

En consecuencia, existe una necesidad de explorar si los biomarcadores EEG de estrés son suficientemente robustos como para generalizar entre dispositivos de distinta naturaleza y distintas configuraciones de electrodos. Por este motivo, en el presente trabajo se diseñará un pipeline DSP reproducible para extraer biomarcadores EEG a partir de formatos de datos heterogéneos.

## II. METODOLOGÍA

### A. Biomarcadores EEG

Para la interpretación de las señales EEG, es usual caracterizar la actividad cerebral identificando distintas bandas de frecuencia, denominadas “ondas cerebrales”. Cada banda de frecuencia se asocia a un estadio diferente de la persona y puede proporcionar información sobre su estado mental (Tabla 1) [10, 11].

Tabla 1. Relación entre potencias de bandas EEG y el

| <i>estrés mental</i> |                                                                                                                                                                                                                                                                                                                                                                       |
|----------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Ondas de EEG         | Relación con el estrés mental                                                                                                                                                                                                                                                                                                                                         |
| Delta (0,5 a 4 Hz)   | Se asocian con los procesos de restauración y regeneración durante el sueño profundo; permitir que el cerebro sintonice ondas delta durante períodos breves puede disminuir la sobreactivación y el pensamiento ansioso asociado al estrés.                                                                                                                           |
| Theta (de 4 a 7 Hz)  | Cuando se produce la onda theta, media y promueve comportamientos importantes, como el aprendizaje y la memoria. En situaciones emocionales inusuales, como el estrés, puede producirse un desequilibrio en tres sistemas de neurotransmisores clave, lo que da lugar a comportamientos                                                                               |
| Alfa (8 a 12 Hz)     | Se ha demostrado que la meditación y la relajación regulares potencian las ondas alfa y disminuyen las ondas beta en las ondas cerebrales relacionadas con el pensamiento y el aprendizaje efectivos. Por ello, son las más recomendadas para reducir el estrés. Cuando la actividad alfa es inexistente o negativa, se sospecha la posibilidad de estrés traumático. |
| Beta (13 a 30 Hz)    | El estrés, como un atasco, provoca sobrecarga y dificulta el procesamiento de las redes neuronales activadas. La onda beta aumenta durante el estrés.                                                                                                                                                                                                                 |
| Gamma (30 a 80 Hz)   | Vinculada a tareas de alta validez ecológica y a un procesamiento cognitivo complejo; niveles excesivos se han asociado con nerviosismo, activación elevada y estrés.                                                                                                                                                                                                 |

Los investigadores utilizan la relación de onda lenta a onda rápida (SW/FW) en las señales de EEG para evaluar el control cortical sobre las funciones subcorticales. Se emplea la relación Alfa/Beta para examinar la correlación entre estas frecuencias prominentes y analizar cambios en el estado cognitivo de un individuo, como los niveles de atención mental. Además, la relación Theta/Beta se introdujo como un marcador de EEG para diagnosticar déficits en la activación y varias facetas del rendimiento cognitivo en individuos. El lóbulo frontal juega un papel crucial en procesos cognitivos como la resolución de problemas, la atención y las interacciones con otras regiones del cerebro. También se sabe que es sensible tanto al estrés agudo como al crónico. Por lo tanto, se ha calculado el nivel de estrés del lóbulo frontal para las

relaciones alfa/beta y theta/beta [10].

**Relación Alfa/Beta:** Un aumento en la potencia de la banda beta y una disminución en la potencia de la banda alfa pueden utilizarse para mostrar un patrón de estrés [11]. Para investigar el avance del estado cognitivo de una persona, como el estrés mental, la relación alfa/beta se ha utilizado para relacionar las dos bandas de frecuencia más importantes [10].

**Relación theta/beta:** Un estudio indicó que una relación theta/beta más alta se asocia con mayores niveles de estrés, lo que sugiere su potencial como indicador de estrés durante tareas cognitivas con demandas variables [10, 11].

Por otro lado, la potencia media de la banda **alfa global** (PSD  $\alpha$  en Fp1+Fp2, 8–12 Hz) constituye un marcador primario adicional, ya que disminuye con la activación cortical [12]. En cambio, la potencia media de la banda **beta global** (PSD  $\beta$  en Fp1+Fp2, 12–30 Hz) se considera un marcador secundario o exploratorio. Aunque teóricamente se asocia a la activación cognitiva, un metaanálisis no encontró un efecto significativo agregado ( $g = -0.31$ ;  $p = 0.29$ ), si bien sí se observaron efectos en estudios individuales [12].

Finalmente, se incluyó la **Asimetría Alfa Frontal (FAA)** ( $\ln(\alpha_{Fp2}) - \ln(\alpha_{Fp1})$ , 8–12 Hz) como marcador exploratorio. Este índice ha sido tradicionalmente vinculado a la valencia emocional a través de la asimetría hemisférica frontal; sin embargo, su evidencia como indicador de estrés resulta débil, dado que un metaanálisis no encontró un efecto significativo para estrés psicosocial ( $g = 0.01$ ;  $p = 0.93$ ), y tampoco se ha reportado evidencia consistente en el contexto de la depresión [12]. Por esta razón, el FAA se considera un marcador de carácter exploratorio, cuya inclusión responde más a su relevancia teórica dentro de la literatura de neurociencia afectiva que a una evidencia empírica robusta para el estrés cognitivo agudo.

## B. Descripción de Datasets

Se utilizaron cuatro conjuntos de datos EEG de origen y formato heterogéneo, resumidos en la Tabla 2. Todos los dispositivos capturan señal desde la región frontal del cuero cabelludo mediante pares de electrodos simétricos izquierda-derecha, lo que permite el cálculo de biomarcadores de asimetría hemisférica en los cuatro casos, aunque las posiciones anatómicas no son idénticas entre datasets.

Tabla 2. Resumen de los datasets EEG utilizados

| Dataset     | Data 1      | Data 2 | Data 3    | Data 4      |
|-------------|-------------|--------|-----------|-------------|
| Dispositivo | Emotiv EPOC | Muse   | ego (PSA) | EEG clínico |
| Electrodos  | AF3/AF      | AF7/A  | Fp1/Fp    | Fp1-A1      |

|            |                            |                                    |                                  |                           |
|------------|----------------------------|------------------------------------|----------------------------------|---------------------------|
|            | 4                          | F8                                 | 2                                | /Fp2-A2                   |
| Formato    | EDF                        | CSV (bandas precalc.)              | CSV en ZIP (2000 Hz)             | EDF                       |
| Fs (Hz)    | 128                        | Variable                           | 2000                             | 200                       |
| Etiquetado | Por paradigma experimental | Nivel moderado (contexto o examen) | EO=Basal, AC1=Moderado, AC2=Alto | Binario: Estrés/No Estrés |

## C. PIPELINE DE PROCESAMIENTO

Cada grabación fue procesada con MNE-Python [13]. En la Figura 1, se puede observar el flujo completo del sistema, donde se utiliza un filtro Butterworth pasa-banda de orden 4 entre 1.0 y 45.0 Hz (filtfilt, fase cero). Posteriormente, se segmentaron en ventanas de 4 segundos sin solapamiento, y para cada ventana se calculó la densidad espectral de potencia (PSD) mediante el método de Welch con  $nperseg = 2 \times Fs$  [14]. La conversión  $ADC \rightarrow \mu V$  para el BITalino sigue:  $EEG(\mu V) = ((raw/1024) - 0.5) \times 3.3/40000 \times 10^6$ .

Los cuatro biomarcadores extraídos por ventana se definen en la Tabla 2. Data 3 y Data 4 son los únicos con canales Fp1/Fp2 anatómicamente equivalentes al NeuroBIT/BITalino, por lo que fueron los únicos usados para entrenar el modelo V3.




Fig. 1. Pipeline completo del sistema: adquisición → conversión ADC → filtrado → segmentación → extracción de biomarcadores → clasificación.

## D. ESTRATEGIAS DE NORMALIZACIÓN

Se utilizan dos estrategias: StandardScaler poblacional multiclase (V2) y normalización por basal propio del participante con clasificación binaria (V3).

- V2 (StandardScaler poblacional): media y SD calculadas sobre el conjunto de entrenamiento multi-dispositivo. Asume comparabilidad de escala entre hardware distinto.

- V3 (Baseline normalization):  $X_{\text{norm}} = (X - \mu_{\text{basal\_propio}}) / (\sigma_{\text{basal\_propio}} + \epsilon)$ . Cancela el domain shift al usar el propio hardware como referencia (Krigolson et al., 2021 [5]; Lotte et al., 2018 [6]). Requiere siempre una grabación basal del mismo participante.

### E. Modelos de clasificación y validación

Se empleó Random Forest con `class_weight='balanced'` [15]. La validación se realizó mediante GroupKFold de 5 particiones agrupando por sujeto, lo que garantizó que ningún sujeto aparezca simultáneamente en entrenamiento y prueba. El modelo V2 multiclase usó las cuatro fuentes (208 muestras agregadas por sujeto-condición). Por otro lado, el modelo V3 binario solo usó Data 3 y Data 4 (34 sujetos con pares basal/estrés reales, 1729 ventanas de 4 s), requisito de la baseline normalization. Para el modelo V3 final se aplicó un aumento de datos de entrenamiento por ventaneo solapado al 50% (1729→3395 ventanas, misma duración grabada, sin sujetos nuevos) y se buscó hiperparámetros (`max_depth`, `n_estimators`, `min_samples_leaf`) validados con GroupKFold, seleccionando la configuración final (`max_depth=8`, `n_estimators=300`, `min_samples_leaf=1`) por robustez de AUC antes que por accuracy puntual, dado el tamaño moderado de la muestra (34 sujetos).

### F. Protocolo de validación con NeuroBIT/BITalino S01

Se realizaron dos grabaciones de la misma sesión con el módulo NeuroBIT de BITalino: Basal (corridas 1 y 2: 14:50h y 15:14h, total 91 ventanas de 4 s) y Estrés (corridas 1 y 2: 14:57h y 15:17h, total 120 ventanas). Las fases de música relajante y música natural se grabaron adicionalmente como control interno de validación del protocolo y no se incluyen en los resultados reportados. Las grabaciones de Basal y Estrés pertenecen a un único participante, pues los datos de un segundo participante que inicialmente formaban parte del dataset fueron excluidos al identificarse la mezcla.

## III. RESULTADOS

### A. Validación fisiológica de Biomarcadores

La Tabla 3 presenta los biomarcadores de S01 comparando Basal y Estrés. Los cuatro biomarcadores primarios muestran diferencias estadísticamente significativas ( $p < 0.001$ ). La FAA no alcanzó significancia ( $p = 0.138$ ), resultado consistente con un metaanálisis para estrés psicosocial [12].

Tabla 3. Biomarcadores EEG

| Biomarcador | Basal             | Estrés            | Cambio         | p-value                              |
|-------------|-------------------|-------------------|----------------|--------------------------------------|
| TBR         | $13.64 \pm 13.04$ | $20.96 \pm 21.08$ | <b>+53.6 %</b> | <b><math>p = 0.003</math> **</b>     |
| Alpha/Betha | $5.470 \pm 1.742$ | $4.053 \pm 2.082$ | <b>-25.9 %</b> | <b><math>p &lt; 0.001</math> ***</b> |

|              |                    |                    |                 |                                      |
|--------------|--------------------|--------------------|-----------------|--------------------------------------|
| Alpha global | $0.171 \pm 0.089$  | $0.306 \pm 0.247$  | <b>+79.0 %</b>  | <b><math>p &lt; 0.001</math> ***</b> |
| Beta global  | $0.031 \pm 0.008$  | $0.081 \pm 0.059$  | <b>+158.6 %</b> | <b><math>p &lt; 0.001</math> ***</b> |
| FAA          | $+0.260 \pm 0.457$ | $+0.123 \pm 0.541$ | <b>-52.9 %</b>  | $p = 0.138$ n.s.                     |

El TBR se incrementa en un 53.6% (de 13.64 a 20.96,  $p=0.003$ ), coherente con la mayor carga atencional de la tarea aritmética [16]. El ratio Alpha/Beta disminuye un 25.9% (de 5.470 a 4.053,  $p<0.001$ ), en una dirección esperada [17]. La potencia Alpha aumenta un 79.0% y la Beta un 158.6%, ambas con  $p<0.001$  e incrementan su potencia absoluta bajo estrés, con Beta creciendo proporcionalmente más, lo que eleva Beta relativa y reduce el ratio A/B de manera coherente con el modelo de activación diferencial. La FAA ( $p=0.138$ ) confirma empíricamente su inclusión exploratoria.




Figura 2. Señales EEG filtradas (Fp1, primeros 10 s) y PSD comparativa por condición con bandas  $\theta/\alpha/\beta$  sombreadas.




Figura 3. Distribución de biomarcadores (boxplot, Mann-Whitney U) y evolución temporal del TBR.

### B. Control interno: validación del protocolo con música

Las grabaciones de música relajante y música natural, usadas únicamente como control interno, mostraron biomarcadores estadísticamente indistinguibles del Basal en todos los marcadores (todos  $p>0.05$ ), confirmando que el estímulo sonoro indujo recuperación fisiológica real del estado de estrés. La comparación Música vs Estrés mostró diferencias significativas en TBR, Alpha/Beta, Alpha global y Beta global (todos

$p < 0.001$ ). Este resultado valida la coherencia del protocolo experimental aunque no forma parte de los resultados reportados.




Figura 4. Control interno — Música vs Basal y Música vs Estrés.

### C. Comparación de estrategias de clasificación

La Tabla 4 y la Figura 5 presentan la comparación entre modelos V2 y V3.

**Tabla 4.** Comparación V2 vs V3. Validación 5-fold GroupKFold agrupado por sujeto.

| Métrica                        | V2 — Multiclase (StandardScaler global)                             | V3 — Binario (baseline normalization)                                                                                 |
|--------------------------------|---------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|
| Tipo de problema               | 3–4 clases (Bajo/Moderado/Alto/Muy Alto)                            | 2 clases (Basal / Estrés)                                                                                             |
| Fuentes de entrenamiento       | Data 1 + 2 + 3 + 4 (208 muestras)                                   | Data 3 + Data 4 únicamente — pares basal/estrés reales (34 sujetos, 1729 ventanas)                                    |
| Normalización                  | StandardScaler poblacional (media/SD del conjunto de entrenamiento) | $(X - \mu_{\text{basal\_propio}}) / (\sigma_{\text{basal\_propio}} + \epsilon)$ — usa el basal del mismo participante |
| Nivel de azar                  | 33.3% (3–4 clases)                                                  | 50.0% (2 clases)                                                                                                      |
| Accuracy 5-fold CV             | $0.562 \pm 0.093$ (IC95%: 0.469–0.655)                              | <b><math>0.724 \pm 0.060</math></b> (ventana) · <b>82.4%</b> (56/68 grabación)                                        |
| F1-macro                       | $0.556 \pm 0.084$                                                   | <b><math>0.707 \pm 0.053</math></b> (macro)                                                                           |
| AUC (holdout)                  | Bajo:0.75, Mod:0.77 Alto:0.48 (macro:0.667)                         | <b><math>0.801 \pm 0.032</math></b> (Estrés vs Basal)                                                                 |
| Validación S01 (BITalino real) | Basal→'Alto' (55.8%)<br>Estrés→'Moderado' (X) — domain shift        | Basal→'Basal' 67.7% (21/31 vent.)<br>Estrés→'Estrés' 90.7% (68/75 vent.) (✓)                                          |




Fig. 5. (a) Accuracy con IC95% respecto al azar de cada modelo; (b) Matriz de confusión V3 (holdout por sujeto); (c) Curvas ROC V2 (one-vs-rest) y V3 (binario).

El modelo V3 mejorado supera ampliamente al V2 en accuracy (0.724 vs 0.562), F1-macro (0.707 vs 0.556) y AUC (0.801 vs 0.667 macro); agregado por grabación completa (68 unidades sujeto×condición), V3 alcanza 82.4% (56/68). Más relevante para la aplicación real: V3 clasifica correctamente el 90.7% de las ventanas de Estrés y el 67.7% de las ventanas Basal de S01, mientras V2 clasifica incorrectamente el basal como 'Alto' (55.8%), evidencia directa del domain shift.

### D. Domain shift entre dispositivos

Al aplicar V2 directamente sobre datos BITalino, el 95.6% de las ventanas basales y el 98.7% de las de estrés se clasificaron como 'Alto', independientemente de la condición real. El TBR del BITalino (basal: 13.6; estrés: 21.0) cae dentro del rango clínico esperado (0.5–20), a diferencia del análisis previo con datos mezclados que producía valores extremos. El StandardScaler global absorbe diferencias sistemáticas de ganancia entre dispositivos en lugar de la variable fisiológica de interés [18, 19].




Figura 6. Análisis del domain shift entre dispositivos y estrategia de publicación.

## IV. DISCUSIÓN

La comparación entre estrategias de normalización revela una limitación conocida en EEG multi-dispositivo: los modelos entrenados con StandardScaler poblacional capturan diferencias sistemáticas de hardware en lugar del estado fisiológico de interés [18, 19]. La baseline normalization (V3) eleva la exactitud a 0.724 por ventana (82.4% por grabación completa) y corrige la clasificación

errónea del basal BITalino, confirmando que normalizar con el propio hardware como referencia es el enfoque correcto para aplicaciones cross-device []. Esta mejora respecto a una versión inicial del mismo modelo (0.678) se obtuvo mediante dos técnicas sin fuga de datos, aumento de datos por ventaneo solapado y ajuste de hiperparámetros validado con GroupKFold, descritas en 2.5, y no mediante datos o sujetos adicionales.

Los resultados de los biomarcadores en S01 son fisiológicamente coherentes con la literatura. El incremento del TBR (53.6%,  $p=0.003$ ) confirma el efecto del estresor aritmético sobre el control atencional prefrontal [16]. Asimismo, la disminución del ratio Alpha/Beta (-25.9%,  $p<0.001$ ) es consistente [17]. La ausencia de significancia en la FAA ( $p=0.138$ ) reproduce exactamente el resultado del metaanálisis ( $g=0.01$ ;  $p=0.93$ ), validando la decisión de incluirla como biomarcador exploratorio [12].

#### A. Sobre el estatus exploratorio de la FAA

La FAA se incluye en este trabajo por su uso extendido en la literatura de asimetría hemisférica frontal, no como marcador primario de estrés. El metaanálisis que sintetizó estudios de las tres fases de la respuesta al estrés psicosocial, encontró un tamaño de efecto no significativo para la FAA ( $g=0.01$ ;  $p=0.93$ ) en contraste con el efecto significativo de la potencia alfa ( $g=0.6$ ;  $p=0.001$ ) [12]. Incluso en depresión, donde la FAA ha sido más estudiada, encontraron un efecto pequeño, concluyendo un valor diagnóstico limitado como marcador aislado [20]. La no-significancia de la FAA en S01 ( $p=0.138$ ) reproduce este patrón de forma empírica, y constituye en sí mismo un resultado relevante al confrontar la hipótesis de uso de la FAA como marcador de estrés con datos propios del hardware objetivo

#### B. Limitaciones

El presente estudio presenta varias limitaciones que deben considerarse al interpretar los resultados. En primer lugar, la validación con el dispositivo BITalino se realizó con un único participante (S01), por lo que los resultados obtenidos no son estadísticamente generalizables a nivel poblacional. En este sentido, la consistencia observada en los biomarcadores primarios debe entenderse como un indicador de coherencia interna del protocolo, y no como evidencia de validez a nivel de población.

Asimismo, la normalización por línea base (baseline normalization) requiere, en todos los casos, una grabación basal de referencia correspondiente al mismo participante y a la misma sesión. Esta condición limita la aplicabilidad del método a escenarios en los que no se cuenta con dicho registro basal, lo cual restringe su uso en contextos de aplicación más flexibles o en tiempo real sin calibración previa.

Por otra parte, el conjunto de datos utilizado para el entrenamiento del modelo V3, compuesto por 34 sujetos, puede considerarse moderado para el desarrollo de un clasificador que busca generalizar entre distintos

dispositivos (cross-device). Un tamaño muestral mayor permitiría fortalecer la capacidad de generalización del modelo y reducir el riesgo de sobreajuste a las características particulares del hardware empleado durante el entrenamiento.

Finalmente, el estudio no incluyó validación mediante cortisol salival, por lo que no fue posible confirmar la inducción del estrés a través de la vía neuroendocrina. Esta limitación es común en estudios piloto que emplean hardware de bajo costo, donde la inclusión de biomarcadores fisiológicos adicionales suele verse restringida por consideraciones logísticas y de recursos.

## V. CONCLUSIONES

En este trabajo se desarrolló un pipeline reproducible capaz de extraer cinco biomarcadores EEG (TBR, Alpha/Beta, Alpha global, Beta global y FAA), compatible con cuatro dispositivos y formatos de datos heterogéneos. A partir de este desarrollo, se comparó el desempeño de dos enfoques de clasificación: el modelo V3, de tipo binario y basado en normalización por línea base, y el modelo V2, de tipo multiclase con StandardScaler. Los resultados mostraron que el modelo V3 supera al V2 en exactitud (0.678 frente a 0.562), en F1 (0.665 frente a 0.556) y en AUC (0.784 frente a 0.667). Además, el modelo V3 corrigió la clasificación errónea observada en el registro basal de BITalino, lo que confirma que la normalización por línea base propia constituye la estrategia más adecuada para aplicaciones cross-device.

La validación realizada sobre el participante S01, con el dispositivo NeuroBIT/BITalino y un conjunto de datos corregido correspondiente a dos corridas, confirmó que el TBR ( $p=0.003$ ) y la relación Alpha/Beta ( $p<0.001$ ) capturan de manera coherente la respuesta al estrés. En contraste, la FAA no alcanzó significancia estadística ( $p=0.138$ ), resultado que resulta consistente con la evidencia previa reportada en la literatura y que respalda su clasificación como biomarcador de carácter exploratorio dentro de este estudio.

El control interno realizado mediante la condición de música arrojó biomarcadores indistinguibles respecto del basal, con valores  $p$  superiores a 0.05 en todos los casos. Este resultado permite validar la coherencia del protocolo experimental empleado, dado que confirma que el sistema no genera falsas detecciones de estrés ante estímulos no estresantes.

Por otro lado, se cuantificó el fenómeno de domain shift entre dispositivos EEG con diferente ganancia, el cual se identificó como una limitación central para la transferencia directa de clasificadores entre plataformas. Este hallazgo constituye un aporte metodológico relevante, dado que combina un análisis con datos propios y una referencia explícita a la literatura sobre transfer learning en interfaces cerebro-computadora (BCI).

Como líneas de trabajo futuro se proponen tres



direcciones principales: primero, ampliar la validación experimental a un mayor número de participantes con el dispositivo BITalino; segundo, incorporar la relación Alpha/Beta (AB\_ratio) como característica explícita durante el reentrenamiento del modelo; y tercero, explorar técnicas de adaptación de dominio (domain adaptation) orientadas a mejorar el desempeño de los clasificadores en contextos cross-device.

## VI. REFERENCES

1. K. Sotelo Castillo and C. Recabarren Jimenez, "Factores asociados al estrés académico en estudiantes universitarios: una revisión crítica," *Universidad Peruana Cayetano Heredia*, 2025. [Online]. Available: <https://hdl.handle.net/20.500.12866/17582>
2. A. Agorastos and G. P. Chrousos, "The neuroendocrinology of stress: the stress-related continuum of chronic disease development," *Molecular Psychiatry*, vol. 27, no. 1, pp. 502–513, Jul. 2021, doi: 10.1038/s41380-021-01224-9.
3. B. Chu, K. Marwaha, T. Sanvictores, and D. Ayers, "Physiology, stress reaction," *StatPearls*, Jul. 2019, [Online]. Available: <https://pubmed.ncbi.nlm.nih.gov/31082164/>
4. World Health Organization: WHO, "Trastornos mentales," Sep. 30, 2025. <https://www.who.int/es/news-room/fact-sheets/detail/mental-disorders>
5. "Estrés afecta a más del 30% de limeños," Noticias - Ministerio De Salud - Plataforma Del Estado Peruano. <https://www.gob.pe/institucion/minsa/noticias/43525-estres-afecta-a-mas-del-30-de-limenos>
6. "Minedu y el Minsa trabajan con 21 universidades públicas en el cuidado de la salud mental," Noticias - Ministerio De Educación - Plataforma Del Estado Peruano. <https://www.gob.pe/institucion/minedu/noticias/52741-minedu-y-el-minsa-trabajan-con-21-universidades-publicas-en-el-cuidado-de-la-salud-mental>
7. A. Arsalan, M. Majid, I. F. Nizami, W. Manzoor, S. M. Anwar, and J. Ryu, "Human Stress Assessment: a comprehensive review of methods using wearable sensors and non-wearable techniques," *arXiv (Cornell University)*, Feb. 2022, doi: 10.48550/arxiv.2202.03033.
8. A. Hag, D. Handayani, T. Pillai, T. Mantoro, M. H. Kit, and F. Al-Shargie, "EEG Mental stress assessment using hybrid Multi-Domain feature sets of functional connectivity network and Time-Frequency features," *Sensors*, vol. 21, no. 18, p. 6300, Sep. 2021, doi: 10.3390/s21186300.
9. D. Mikhaylov, M. Saeed, M. H. Alhosani, and Y. F. A. Wahedi, "Comparison of EEG Signal Spectral Characteristics Obtained with Consumer- and Research-Grade Devices," *Sensors*, vol. 24, no. 24, p. 8108, Dec. 2024, doi: 10.3390/s24248108.
10. Y. Dasari, L. R. Chebolu, and V. Balasubramanian, "Electroencephalogram analysis on alpha/beta and theta/beta ratios due to shirodhara," *Journal of Ayurveda and Integrative Medicine*, vol. 16, no. 2, p. 101094, Mar.–Apr. 2025, doi: 10.1016/j.jaim.2024.101094.
11. E. T. Attar, "Review of electroencephalography signals approaches for mental stress assessment," *Neurosciences (Riyadh)*, vol. 27, no. 4, pp. 209–215, Oct. 2022, doi: 10.17712/nsj.2022.4.20220025.
12. G. Vanhollenbeke, S. De Smet, R. De Raedt, C. Baeken, P. Van Mierlo, and M.-A. Vanderhasselt, "The neural correlates of psychosocial stress: A systematic review and meta-analysis of spectral analysis EEG studies," *Neurobiology of Stress*, vol. 18, p. 100452, Apr. 2022, doi: 10.1016/j.ynstr.2022.100452.
13. A. Gramfort, "MEG and EEG data analysis with MNE-Python," *Frontiers in Neuroscience*, vol. 7, p. 267, Jan. 2013, doi: 10.3389/fnins.2013.00267.
14. P. Welch, "The use of fast Fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms," *IEEE Transactions on Audio and Electroacoustics*, vol. 15, no. 2, pp. 70–73, Jun. 1967, doi: 10.1109/tau.1967.1161901.
15. L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, Oct. 2001, doi: 10.1023/a:1010933404324.
16. P. Putman, B. Verkuil, E. Arias-Garcia, I. Pantazi, and C. Van Schie, "EEG theta/beta ratio as a potential biomarker for attentional control and resilience against deleterious effects of stress on attention," *Cognitive Affective & Behavioral Neuroscience*, vol. 14, no. 2, pp. 782–791, Dec. 2013, doi: 10.3758/s13415-013-0238-7.
17. T. Y. Wen and S. A. M. Aris, "Electroencephalogram (EEG) stress analysis on alpha/beta ratio and theta/beta ratio," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 17, no. 1, p. 175, Jan. 2020, doi: 10.11591/ijeecs.v17.i1.pp175-182.
18. V. Jayaram, M. Alamgir, Y. Altun, B. Scholkopf, and M. Grosse-Wentrup, "Transfer Learning in Brain-Computer Interfaces Abstract\u00FFFDThe performance of brain-computer interfaces (BCIs) improves with the amount of avail," *IEEE Computational Intelligence Magazine*, vol. 11, no. 1, pp. 20–31, Jan. 2016, doi: 10.1109/mci.2015.2501545.
19. D. Wu, Y. Xu, and B.-L. Lu, "Transfer Learning for EEG-Based Brain-Computer Interfaces: A review of progress made since 2016," *IEEE*

*Transactions on Cognitive and Developmental Systems*, vol. 14, no. 1, pp. 4–19, Jul. 2020, doi: 10.1109/tcds.2020.3007453.

20. Y. Luo, M. Tang, and X. Fan, “Meta analysis of resting frontal alpha asymmetry as a biomarker of depression,” *Npj Mental Health Research*, vol. 4, no. 1, p. 2, Jan. 2025, doi: 10.1038/s44184-025-00117-x.